🎓 Защита курсового проекта по Базам Данных

Оценка окупаемости фильмов и влияние бюджета на коммерческий успех

ПРОЕКТ-МЕНЕДЖЕР
Ивакина Софья

DATA SPECIALIST
Матус Степан

SQL DEVELOPER
Татиев Тамерлан

BI & EXCEL SPECIALIST
Петренко Артем

Цели проекта и проверяемые гипотезы

Ивакина Софья

Главная цель

Проектирование нормализованной БД (200 фильмов) и выявление закономерностей между бюджетом, окупаемостью и рейтингами.

Организация работы

Гибридный формат: аудиторные спринты по архитектуре + онлайн-синхронизация SQL/Excel в GitHub и Notion.

Гипотеза №1 (Бюджет и касса)

Предположение: Высокий бюджет гарантирует максимальный коммерческий доход и зрительский рейтинг.

Гипотеза №2 (Оценки критиков)

Предположение: Жанр «Драма» безусловно лидирует по оценкам критиков среди всех категорий.

Источник данных и результаты аудита (Data Pipeline)

Матус Степан

200

Записей в The Movies Dataset

Параметры: бюджеты, сборы, жанры, даты, студии, хронометраж и оценки.

⚠ Обнаруженные проблемы данных

- **Сдвинутые строки:** Попадание названий в числовые поля финансовых показателей.
- **Нерегулярные списки:** Жанры указаны через запятую в одной ячейке.
- **Пропуски и дубли:** Отсутствие дат и повторяющиеся записи наименований.

Метод очистки данных

Разделение текстовых массивов, валидация внешних ключей и фильтрация нулевых значений бюджетов до загрузки в SQL.

Архитектура базы данных (3НФ) и структура таблиц

Татиев Тамерлан

Структура 6 таблиц БД

- **movies & finances** (1:1) — изоляция бюджетов и кассовых сборов.
- **movies & ratings** (1:1) — отдельное хранение показателей голосования.
- **companies & movies** (1:N) — привязка фильмов к киностудиям.
- **movies & genres** (M:N) — связь через таблицу *critic_genre_evaluations*.

Третья нормальная форма (3НФ)

Устранены транзитивные зависимости и дублирование текста. Все неключевые атрибуты зависят строго от первичного ключа (PK) своей таблицы.

Ключевые таблицы модели

- **movies:** id (PK), title, release_date, runtime, original_language
- **finances:** finance_id (PK), movie_id (FK), budget, revenue, profit_status
- **ratings:** rating_id (PK), movie_id (FK), vote_average, vote_count
- **genres:** genre_id (PK), genre_name, age_rating, description
- **companies:** company_id (PK), company_name, country, company_type
- **critic_genre_evaluations:** evaluation_id (PK), movie_id (FK), genre_id (FK), critic_genre_score

Валидация данных через SQL-запросы

Татиев Тамерлан

Поиск пропусков и повторов

```sql
SELECT COUNT(*) - COUNT(title) AS missing_titles
FROM movies;

SELECT title, COUNT(*)
FROM movies
GROUP BY title
HAVING COUNT(*) > 1;
```

Проверка аномалий: Подтверждено отсутствие нулевых названий и дублирующихся строк.

Контроль целостности (FK)

```sql
SELECT f.finance_id, f.movie_id
FROM finances f
LEFT JOIN movies m ON f.movie_id = m.id
WHERE m.id IS NULL;
```

Проверка связей: Выявлено 0 «осиротевших» записей в финансовых показателях.

Результаты: Зависимость бюджета, сборов и рейтинга

Петренко Артем

Топовые фильмы по зрительскому рейтингу (Excel Export)

Фильм	Бюджет ($)	Сборы ($)	Рейтинг
Batman Begins	16 000 000	391 961 380	**9.5**
Shutter Island	146 000 000	252 745 549	**9.5**
The Matrix Reloaded	102 000 000	291 073 225	**9.5**
Million Dollar Baby	242 000 000	689 829 723	9.4
Interstellar	235 000 000	680 879 203	9.3

✕ Гипотеза №1 ОПРОВЕРГНУТА

Финансовая окупаемость и высочайший рейтинг (9.5) зафиксированы как у среднебюджетных картин (от $16 млн), так и у крупных блокбастеров ($200 млн+).

Аналитический вывод

Высокий бюджет не гарантирует пропорционального роста зрительской оценки или доходности.

Результаты: Оценки критиков по жанрам (>8.5)

Петренко Артем

Сводные показатели экспертных оценок (critic_genre_score)

Жанр (Genre)	Средний балл	Количество топов (>8.5)
Crime	**9.50**	14 фильмов
Thriller	9.43	14 фильмов
Sci-Fi	9.43	14 фильмов
Animation	9.38	**16 фильмов**
Drama	9.23	13 фильмов
Action	9.15	13 фильмов

✕ Гипотеза №2 ОПРОВЕРГНУТА

Драма не доминирует: по среднему баллу лидирует жанр **Crime (9.5)**, а по количеству топов — **Animation (16 фильмов)**.

Аналитический вывод

Экспертная критика отдает предпочтение криминальным триллерам и качественной анимации.

Итоги, ограничения и вопросы

Ивакина Софья

Главные выводы

• Опровергнуты стереотипы о прямой связи бюджета с успехом и доминировании драм.
• Успешно построена нормализованная БД в 3НФ с полной целостностью связей.

Ограничения проекта

• Размер выборки: анализировалась подвыборка из 200 записей.
• Фиксированный порог отбора экспертных оценок (>8.5).

Спасибо за внимание!

Команда проекта готова ответить на ваши вопросы